

1. SUMMARY & PURPOSE

1.1 Dataset Description

Empty Glass vs Filled Glass Image Dataset adalah dataset citra yang dirancang untuk melakukan klasifikasi kondisi gelas berdasarkan keberadaan cairan di dalamnya. Dataset terdiri dari dua kelas utama, yaitu Empty Glass dan Filled Glass. Data utama dataset berupa citra original yang akan diperoleh melalui proses data acquisition secara mandiri. Proses pengambilan gambar akan dilakukan dengan mempertimbangkan beberapa variasi objek dan kondisi pengambilan untuk menghasilkan keberagaman visual yang relevan dengan tujuan klasifikasi.

Dataset juga akan dilengkapi dengan metadata tabular yang mencatat informasi mengenai karakteristik objek dan kondisi acquisition setiap citra. Metadata tersebut digunakan untuk mendukung dokumentasi, quality control, serta analisis terhadap distribusi data.

1.2 Curation Rationale

Dataset ini dikembangkan berdasarkan permasalahan pengenalan kondisi gelas secara otomatis melalui informasi visual. Meskipun manusia dapat membedakan gelas kosong dan gelas berisi cairan secara visual, sistem komputer memerlukan data citra yang terstruktur dan representatif untuk mempelajari karakteristik visual yang berkaitan dengan kondisi tersebut.

Pengumpulan data dilakukan secara mandiri untuk memperoleh data original dengan proses acquisition yang terdokumentasi dan dapat dikendalikan. Pendekatan ini memungkinkan karakteristik pengambilan data, variasi objek, kondisi lingkungan, serta metadata yang menyertainya ditentukan sesuai dengan kebutuhan penelitian.

Dataset juga dirancang untuk meminimalkan ketergantungan model terhadap karakteristik yang tidak relevan, seperti background atau kondisi pencahayaan tertentu, dengan mempertimbangkan variasi acquisition dan distribusi data selama proses pengumpulan.

1.3 Task

Task: Image Classification

Type: Binary Classification

Dataset terdiri dari dua kelas:

Class	Definition
Empty Glass	Gelas yang tidak memiliki volume cairan yang dapat dianggap sebagai isi utama gelas.
Filled Glass	Gelas yang memiliki cairan dalam jumlah yang dapat diamati secara visual sebagai isi gelas.

1.4 Intended Decision

Dataset digunakan untuk mendukung pengembangan model Machine Learning/Deep Learning berbasis computer vision yang dapat menentukan kondisi gelas berdasarkan citra.

Keputusan yang didukung oleh dataset adalah:

“Apakah gelas yang terlihat pada sebuah citra berada dalam kondisi kosong atau mengandung cairan sebagai isi utama?”

Output klasifikasi terdiri dari dua kemungkinan:

Empty Glass atau Filled Glass

2. COMPOSITION & UNIT

2.1 Dataset Modality

Dataset menggunakan citra digital (image) sebagai modality utama. Setiap citra menampilkan satu objek gelas sebagai objek utama yang diamati berdasarkan kondisi keberadaan cairan di dalamnya.

Selain citra, dataset dilengkapi dengan metadata tabular yang mendeskripsikan karakteristik objek, kondisi cairan, serta kondisi pengambilan gambar. Metadata digunakan untuk mendukung dokumentasi, quality control, traceability, dan analisis terhadap distribusi dataset.

2.2 Unit of Data

Satu unit data (*data point/sample*) didefinisikan sebagai satu file citra original yang menampilkan satu gelas pada kondisi tertentu.

Setiap citra memiliki satu label kelas yang menunjukkan kondisi gelas, yaitu:

- Empty Glass
- Filled Glass

Setiap citra memiliki identitas unik (*image_id*) dan direpresentasikan oleh satu baris pada file metadata tabular.

Contohnya:

image_id	image_file	label
IMG001	IMG001.jpg	Empty Glass
IMG002	IMG002.jpg	Filled Glass
IMG003	IMG003.jpg	Empty Glass

Dengan definisi ini, 1 gambar = 1 sample/data point.

2.3 Class Composition

Dataset menggunakan dua kelas untuk tugas binary image classification, yaitu Empty Glass dan Filled Glass.

Class	Deskripsi
Empty Glass	Gelas tidak mengandung cairan
Filled Glass	Gelas mengandung cairan yang terlihat secara visual

Untuk distribusi:

Target Minimum Dataset

Kelas	Minimum
Empty Glass	25
Filled Glass	25
Total	50

Target Data Acquisition

Kelas	Target
Empty Glass	35
Filled Glass	35
Total	70

Untuk menjaga keseimbangan kelas, dataset dirancang dengan jumlah sampel yang relatif seimbang antara Empty Glass dan Filled Glass. Target data acquisition ditetapkan sebanyak 70 citra original, yang terdiri dari 35 citra Empty Glass dan 35 citra Filled Glass. Sementara itu, jumlah minimum dataset final ditetapkan sebanyak 50 citra, yang terdiri dari sekurang-kurangnya 25 citra pada masing-masing kelas.

Perbedaan antara target acquisition dan minimum dataset final digunakan sebagai buffer untuk quality control, sehingga sebagian citra dapat ditolak apabila tidak memenuhi kriteria kualitas tanpa menyebabkan jumlah dataset final berada di bawah batas minimum.

2.4 Data Diversity

Dataset dirancang untuk mencakup variasi visual yang relevan terhadap task klasifikasi. Variasi tidak hanya ditujukan untuk memperbanyak jumlah citra, tetapi untuk merepresentasikan kondisi acquisition yang berbeda sehingga dataset tidak terlalu bergantung pada satu objek atau satu kondisi tertentu.

Variasi objek

- bentuk dan ukuran gelas;
- jenis material gelas;
- desain atau karakteristik fisik gelas.

Variasi kondisi isi

- jenis cairan;

- tingkat pengisian cairan;
- karakteristik visual cairan, seperti warna atau kejernihan, apabila relevan.

Variasi pengambilan gambar

- sudut kamera;
- jarak kamera terhadap objek;
- orientasi objek;
- posisi objek dalam frame.

Variasi lingkungan

- kondisi pencahayaan;
- background;
- lingkungan indoor atau outdoor, apabila digunakan.

Variasi tersebut dipertimbangkan untuk meningkatkan keberagaman dataset sekaligus mengurangi ketergantungan model terhadap karakteristik tertentu yang tidak menjadi target klasifikasi.

2.5 Variation Constraint

Setiap variasi spesifik, seperti jenis atau desain gelas, jenis cairan, atau kondisi pengambilan tertentu, diusahakan tidak melebihi sekitar 10 citra agar tidak mendominasi dataset. Pembatasan ini diterapkan untuk menjaga keberagaman data dan mengurangi kemungkinan model mempelajari karakteristik spesifik suatu variasi daripada kondisi gelas yang menjadi target klasifikasi.

2.6 Metadata / Tabular Data

Dataset dilengkapi dengan metadata tabular yang digunakan untuk mendokumentasikan karakteristik setiap citra dan kondisi acquisition. Setiap baris pada metadata merepresentasikan satu citra berdasarkan image_id.

Metadata dirancang untuk memuat informasi yang berkaitan dengan identitas data, label, karakteristik gelas, kondisi isi, serta parameter acquisition.

Struktur metadata

Field	Deskripsi	Contoh
image_id	ID unik citra	IMG001
filename	Nama file citra	IMG001.jpg

label	Label klasifikasi	Filled Glass
glass_type	Jenis/bentuk gelas	Mug
glass_material	Material gelas	Glass
liquid_type	Jenis cairan	Water
fill_level	Tingkat pengisian	70%
camera_angle	Sudut pengambilan	45°
camera_distance	Jarak kamera	50 cm
lighting_condition	Kondisi pencahayaan	Bright
background	Jenis background	White Table
orientation	Orientasi gambar/objek	Vertical
object_position	Posisi gelas dalam frame	Center
device	Perangkat acquisition	Smartphone
location_type	Tipe lingkungan	Indoor
capture_date	Tanggal acquisition	YYYY-MM-DD
quality_status	Status hasil QC	Accepted
rejection_reason	Alasan rejection, jika ada	—

2.7 Dataset Structure

```

empty-glass-vs-filled-glass/
├── raw/
│   ├── empty_glass/
│   └── filled_glass/
│
├── processed/
│
├── augmented/
│
├── metadata/
│   └── dataset_metadata.csv
│
└── documentation/

```

```
└── dataset_card.md
```

Folder raw/ digunakan untuk menyimpan seluruh citra original hasil data acquisition dan menjadi sumber data utama sebelum preprocessing. Folder processed/ digunakan untuk menyimpan data setelah proses preprocessing, sedangkan folder augmented/ digunakan untuk menyimpan data hasil augmentation setelah tahap tersebut dilakukan dalam workflow penelitian.

File dataset_metadata.csv menyimpan informasi tabular yang terkait dengan setiap citra. Folder documentation/ digunakan untuk menyimpan dokumentasi dataset, termasuk Dataset Card.

Dan contoh hubungan data:

```
IMG001
├── raw/empty_glass/IMG001.jpg
└── metadata → label = Empty Glass

IMG002
├── raw/filled_glass/IMG002.jpg
└── metadata → label = Filled Glass
```

3. COLLECTION PROCESS

3.1 Source Data

Data utama dataset berupa citra digital gelas yang akan dikumpulkan secara mandiri melalui proses data acquisition. Objek yang digunakan berupa gelas nyata yang diamati dalam dua kondisi utama, yaitu Empty Glass dan Filled Glass.

Sumber citra berasal dari hasil pengambilan gambar secara langsung menggunakan perangkat kamera/smartphone dan bukan dari dataset publik, mesin pencari gambar, maupun sumber citra eksternal sebagai sumber utama.

Setiap citra yang diperoleh akan disimpan sebagai data original dan dicatat bersama informasi acquisition yang relevan sebelum memasuki tahap preprocessing atau augmentation.

3.2 Data Acquisition

Data acquisition dilakukan dengan mengambil foto gelas secara langsung menggunakan smartphone. Pengambilan gambar dilakukan pada kondisi Empty Glass dan Filled Glass dengan mempertimbangkan variasi objek, kondisi isi, sudut kamera, jarak pengambilan, pencahayaan, background, dan orientasi objek.

Target acquisition adalah 70 citra original, yang terdiri dari 35 citra Empty Glass dan 35 citra Filled Glass. Jumlah tersebut digunakan sebagai target pengumpulan sebelum proses quality control, sedangkan dataset final harus memiliki sedikitnya 50 citra yang memenuhi kriteria kualitas.

Setiap citra diberi image_id yang unik dan dicatat dalam metadata untuk menjaga keterlacakan antara file gambar dan informasi acquisition.

Tahapan acquisition secara umum:

Menentukan objek → Menentukan kondisi gelas → Mengatur lingkungan → Mengambil gambar → Memberikan ID → Mencatat metadata → Quality checking

3.3 Collection Protocol

Pengambilan data menggunakan pendekatan controlled variation, yaitu menentukan variasi yang akan direpresentasikan sebelum proses acquisition dilakukan. Variasi dibuat tetap relevan dengan task klasifikasi dan tidak dimaksudkan untuk menghasilkan kombinasi kondisi secara berlebihan.

Faktor yang dikontrol

Objek

- jenis/bentuk gelas;
- ukuran gelas;
- material gelas;
- desain atau karakteristik fisik gelas.

Kondisi isi

- Empty Glass;
- Filled Glass;
- jenis cairan;
- tingkat pengisian.

Pengambilan gambar

- sudut kamera;
- jarak kamera;
- orientasi objek;
- posisi objek dalam frame.

Lingkungan

- pencahayaan;
- background;
- lokasi/tipe lingkungan.

Setiap variasi dicatat dalam metadata sehingga distribusi data dapat diperiksa setelah acquisition selesai.

3.4 Sampling Strategy

Pengumpulan data menggunakan strategi controlled variation sampling dengan menentukan variasi objek dan kondisi acquisition terlebih dahulu, kemudian mengambil citra secara bertahap dari setiap variasi yang telah ditentukan.

Target acquisition ditetapkan sebanyak 70 citra original, dengan distribusi:

Kelas	Target
Empty Glass	35
Filled Glass	35
Total	70

Dataset final harus memiliki sekurang-kurangnya 50 citra valid, dengan minimum 25 citra pada masing-masing kelas. Selisih antara target acquisition dan minimum dataset final berfungsi sebagai buffer untuk quality control, sehingga citra yang tidak memenuhi kriteria dapat ditolak tanpa menyebabkan jumlah dataset final berada di bawah batas minimum.

Pengambilan gambar tidak dilakukan dengan memperbanyak citra yang secara visual identik dari satu objek dan satu kondisi. Variasi acquisition didistribusikan untuk mengurangi dominasi satu jenis objek, kondisi, atau lingkungan tertentu.

3.5 Data Processing During Collection

Pada tahap data acquisition, citra dipertahankan sebagai data original dan tidak dilakukan augmentation.

Processing pada tahap collection hanya mencakup aktivitas yang diperlukan untuk pengelolaan dan validasi data awal, seperti:

- pemberian image_id dan nama file;
- pencatatan metadata;
- pengecekan file corrupt;
- pemeriksaan kualitas visual awal;
- identifikasi kemungkinan duplikasi;
- pencatatan label awal.

Transformasi seperti rotation, flipping, cropping, scaling, color transformation, noise injection, atau synthetic augmentation tidak dilakukan pada data original selama tahap acquisition.

Data original akan dipertahankan sebagai sumber utama dan menjadi dasar untuk tahap preprocessing atau augmentation pada tahap workflow yang telah ditentukan.

3.6 Collection Location & Environment

Data acquisition dilakukan pada lingkungan yang memungkinkan objek dan kondisi pengambilan gambar dikontrol, seperti lingkungan indoor yang sesuai dengan kebutuhan acquisition.

Informasi mengenai tipe lingkungan, pencahayaan, dan background dicatat dalam metadata untuk setiap citra. Variasi lingkungan digunakan secara terkontrol untuk memastikan bahwa dataset tidak seluruhnya bergantung pada satu kondisi visual.

Lokasi spesifik acquisition akan dicatat berdasarkan tempat pengambilan data yang sebenarnya.

3.7 Acquisition Metadata

Setiap citra yang diperoleh selama proses acquisition dicatat menggunakan metadata untuk menjaga traceability dan mendokumentasikan kondisi saat data dikumpulkan.

Metadata dicatat pada saat atau segera setelah acquisition dilakukan dan dihubungkan dengan image_id yang unik.


Contoh:

Field	Contoh
image_id	IMG001
filename	IMG001.jpg
label	Filled Glass
glass_type	Mug
glass_material	Glass
liquid_type	Water
fill_level	50%
camera_angle	45°
camera_distance	50 cm
lighting_condition	Bright
background	White Table
orientation	Vertical
object_position	Center
device	Smartphone
location_type	Indoor
capture_date	YYYY-MM-DD

Metadata tersebut digunakan untuk mengetahui kondisi acquisition dari setiap citra, mendukung quality control, mengevaluasi distribusi variasi, dan membantu mengidentifikasi sumber bias potensial dalam dataset.

3.8 Acquisition Workflow

Proses data acquisition dilakukan melalui tahapan berikut:



Memberikan Image ID



Mencatat Metadata



Pemeriksaan Awal



Quality Control



Dataset Final

4. LABELS & QUALITY

4.1 Label Definitions

Dataset menggunakan dua label utama untuk tugas binary image classification, yaitu Empty Glass dan Filled Glass.

Label	Definisi
Empty Glass	Gelas tidak memiliki volume cairan yang dapat dianggap sebagai isi utama gelas.
Filled Glass	Gelas memiliki cairan dalam jumlah yang dapat diamati secara visual sebagai isi utama gelas.

Penentuan label didasarkan pada kondisi aktual gelas pada saat citra diambil, bukan berdasarkan jenis, bentuk, warna, atau material gelas.

4.2 Labeling Criteria

Empty Glass

Sebuah citra diberikan label Empty Glass apabila:

- tidak terdapat cairan yang membentuk isi utama gelas;
- gelas dapat diamati dengan cukup jelas;
- kondisi gelas tidak menunjukkan adanya volume cairan yang signifikan.

Sisa tetesan atau residu kecil yang tidak membentuk isi utama gelas tidak secara otomatis mengubah label menjadi Filled Glass.

Filled Glass

Sebuah citra diberikan label Filled Glass apabila:

- terdapat cairan yang membentuk isi utama gelas;
- keberadaan cairan dapat diamati secara visual;
- tingkat pengisian dapat dibedakan atau diperkirakan sesuai metadata yang digunakan.

Apabila kondisi gelas tidak dapat ditentukan secara meyakinkan karena refleksi, transparansi, objek terhalang, pencahayaan, atau kualitas citra, data diberikan status ambiguous untuk ditinjau kembali dan tidak langsung dimasukkan ke dataset final.

4.3 Annotation Process

Pelabelan dilakukan secara manual berdasarkan pemeriksaan visual terhadap setiap citra hasil data acquisition.

Proses labeling dilakukan dengan tahapan:

Citra diperiksa → kondisi gelas ditentukan → label diberikan → metadata dicatat → quality review → status akhir ditentukan.

Setiap citra diberikan identitas unik (`image_id`) dan label klasifikasi. Apabila terdapat keraguan terhadap label, citra masuk ke tahap quality review sebelum ditetapkan sebagai bagian dari dataset final.

Label diberikan berdasarkan pedoman definisi kelas yang telah ditetapkan pada Section 4.1 dan 4.2.

4.4 Annotators

Dataset diberi label oleh satu annotator menggunakan pedoman labeling yang telah ditentukan.

Annotator menggunakan pedoman labeling yang sama untuk menjaga konsistensi penentuan kelas.

4.5 Quality Control

Quality control dilakukan untuk memastikan bahwa citra yang masuk ke dataset final memiliki kualitas visual yang memadai, label yang sesuai, serta metadata yang lengkap dan konsisten.

Pemeriksaan dibagi menjadi tiga aspek.

A. Technical Quality

- file dapat dibuka dan tidak corrupt;
- resolusi gambar memadai;
- gambar tidak mengalami blur berat;
- objek gelas terlihat dengan jelas.

B. Label Quality

- kondisi Empty Glass atau Filled Glass dapat ditentukan;
- label sesuai dengan kondisi aktual gelas;
- tidak terdapat ketidaksesuaian antara label dan metadata;

- citra ambigu ditinjau ulang sebelum diterima.

C. Dataset Quality

- tidak terdapat duplikasi;
- distribusi kelas diperiksa;
- variasi tertentu tidak mendominasi dataset;
- metadata setiap sample lengkap;
- citra memenuhi protokol acquisition.

4.6 Rejection Criteria

Citra diberikan status rejected dan tidak dimasukkan ke dataset final apabila memenuhi salah satu atau lebih kondisi berikut:

1. Severe blur: gambar terlalu blur sehingga kondisi gelas sulit diamati.
2. Object unclear: objek gelas tidak terlihat atau sebagian besar tertutup.
3. Ambiguous condition: kondisi kosong atau berisi tidak dapat ditentukan secara meyakinkan.
4. Corrupt file: file gambar rusak atau tidak dapat dibuka.
5. Duplicate: gambar merupakan duplikat atau hampir identik dengan data lain.
6. Protocol violation: gambar tidak memenuhi protokol acquisition yang telah ditentukan.
7. Incomplete metadata: informasi penting pada metadata tidak tersedia dan tidak dapat dipulihkan.

Untuk menjaga traceability, data yang ditolak tidak langsung dihapus tanpa catatan. Statusnya dicatat dalam metadata.

Contoh:

image_id	quality_status	rejection_reason
IMG041	Rejected	Severe blur
IMG042	Rejected	Duplicate
IMG043	Accepted	—

4.7 Quality Audit

Setelah seluruh proses acquisition dan labeling selesai, dilakukan final quality audit sebelum dataset digunakan untuk preprocessing dan pemodelan.

Audit mencakup:

- jumlah total citra yang berhasil dikumpulkan;
- jumlah citra pada masing-masing kelas;
- jumlah citra yang diterima dan ditolak;
- keseimbangan kelas;
- distribusi variasi objek dan kondisi acquisition;
- duplikasi;
- konsistensi label;
- kelengkapan metadata.

Hasil audit digunakan untuk menentukan dataset final.

5. PRIVACY & LICENSE

5.1 Personal and Sensitive Information

Dataset dirancang agar fokus pada objek gelas sebagai objek utama dan tidak ditujukan untuk mengumpulkan informasi pribadi atau data sensitif.

Selama proses acquisition, pengambilan gambar diupayakan untuk menghindari informasi yang dapat mengidentifikasi individu, seperti:

- wajah atau identitas seseorang;
- kartu identitas atau dokumen pribadi;
- nomor telepon atau informasi kontak;
- alamat atau informasi pribadi lainnya;
- informasi sensitif lain yang tidak relevan dengan tujuan dataset.

Apabila informasi pribadi atau sensitif secara tidak sengaja muncul pada suatu citra, citra tersebut akan ditinjau dan dapat dikeluarkan dari dataset final.

5.2 Privacy Considerations

Proses data acquisition dilakukan dengan memperhatikan privasi lingkungan tempat pengambilan gambar. Objek utama dalam citra adalah gelas, sedangkan elemen lain yang tidak berkaitan dengan task klasifikasi diusahakan seminimal mungkin.

Metadata hanya mencatat informasi yang relevan dengan karakteristik data dan proses acquisition, seperti jenis gelas, jenis cairan, kondisi pencahayaan, background, perangkat, dan tanggal pengambilan. Informasi pribadi yang tidak diperlukan untuk penelitian tidak dicatat.

Sebelum dataset final digunakan, citra dan metadata akan diperiksa untuk memastikan tidak terdapat informasi pribadi atau sensitif yang tidak diperlukan.

5.3 License

Dataset ditujukan untuk keperluan akademik, pembelajaran, dan penelitian terkait Machine Learning/Deep Learning dan klasifikasi citra. Ketentuan distribusi dan penggunaan dataset akan ditetapkan sesuai dengan tujuan publikasi dataset.

5.4 Data Ownership

Citra yang digunakan dalam dataset berasal dari data acquisition yang dilakukan secara mandiri oleh pembuat dataset. Dataset tidak menggunakan citra eksternal sebagai sumber utama.

Kepemilikan dan hak penggunaan terhadap data mengikuti pihak yang melakukan acquisition serta ketentuan institusi atau platform tempat dataset dipublikasikan.

6. USES, LIMITS & MAINTENANCE

6.1 Direct Use

Dataset ditujukan untuk pengembangan dan evaluasi sistem computer vision yang melakukan klasifikasi kondisi gelas berdasarkan citra.

Penggunaan yang sesuai meliputi:

- pengembangan model Machine Learning/Deep Learning untuk binary image classification;
- eksperimen menggunakan Convolutional Neural Network (CNN) atau arsitektur computer vision lainnya;
- pembelajaran mengenai preprocessing, feature learning, training, dan evaluasi model;
- analisis pengaruh variasi objek dan kondisi acquisition terhadap performa model klasifikasi.

Task utama yang didukung oleh dataset adalah:

Mengklasifikasikan apakah sebuah gelas pada citra berada dalam kondisi Empty Glass atau Filled Glass.

6.2 Out-of-Scope Use

Dataset tidak dirancang untuk penggunaan yang memerlukan akurasi, keandalan, atau generalisasi tinggi pada kondisi dunia nyata yang tidak direpresentasikan dalam dataset.

Dataset tidak ditujukan secara khusus untuk:

- mengukur volume cairan secara presisi;
- mengidentifikasi jenis atau komposisi cairan secara akurat;
- menentukan merek atau tipe gelas;
- menilai kualitas atau keamanan cairan;
- mendukung keputusan pada sistem otomatis yang bersifat kritis.

Model yang dikembangkan menggunakan dataset ini tidak boleh diasumsikan memiliki performa yang sama ketika diterapkan pada objek, lingkungan, atau perangkat yang berbeda dari kondisi acquisition dataset.

6.3 Bias

Dataset berpotensi memiliki sampling bias karena data diperoleh melalui proses acquisition mandiri dengan jumlah sampel yang relatif kecil dan kondisi pengumpulan yang terbatas.

Beberapa sumber bias potensial meliputi:

Object Bias

Jenis, bentuk, ukuran, atau material gelas tertentu dapat muncul lebih sering dibandingkan variasi lainnya.

Environmental Bias

Distribusi background dan kondisi pencahayaan tertentu dapat lebih dominan dibandingkan kondisi lainnya.

Device Bias

Karakteristik kamera atau smartphone yang digunakan dapat memengaruhi warna, pencahayaan, ketajaman, dan karakteristik visual citra.

Liquid Bias

Jenis, warna, atau tingkat kejernihan cairan tertentu dapat lebih sering muncul pada kelas Filled Glass sehingga berpotensi menjadi fitur yang digunakan model.

Acquisition Bias

Sudut kamera, jarak pengambilan, posisi objek, dan cara pengambilan gambar dapat menghasilkan distribusi visual tertentu yang tidak sepenuhnya mewakili kondisi di luar dataset.

Potensi bias tersebut perlu diperhatikan ketika mengevaluasi kemampuan generalisasi model.

6.4 Risks

Salah satu risiko utama adalah model mempelajari shortcut features, yaitu karakteristik visual yang berkorelasi dengan label tetapi bukan merupakan karakteristik utama yang ingin dipelajari.

Contohnya, model dapat mempelajari hubungan seperti:

Background tertentu → Filled Glass

Warna cairan tertentu → Filled Glass

Jenis gelas tertentu → Filled Glass

daripada benar-benar mempelajari keberadaan cairan di dalam gelas.

Risiko lain adalah penurunan performa apabila model diberikan data dengan:

- jenis gelas yang belum pernah dilihat;
- jenis atau warna cairan yang berbeda;
- kondisi pencahayaan berbeda;
- background berbeda;
- perangkat kamera berbeda;
- sudut pengambilan berbeda.

Oleh karena itu, evaluasi model perlu mempertimbangkan kondisi di luar distribusi acquisition dan tidak hanya mengandalkan satu metrik performa.

6.5 Limitations

Dataset memiliki beberapa keterbatasan yang perlu dipertimbangkan ketika digunakan untuk pengembangan maupun evaluasi model.

1. Ukuran dataset relatif kecil, dengan target acquisition sebanyak 70 citra dan minimum dataset final sebanyak 50 citra.
2. Jumlah sampel yang terbatas membatasi jumlah variasi jenis gelas, cairan, lingkungan, dan kondisi acquisition yang dapat direpresentasikan.
3. Dataset hanya terdiri dari dua kelas, sehingga belum mencakup klasifikasi kondisi gelas yang lebih kompleks.
4. Gelas transparan dapat menghasilkan refleksi, distorsi, atau efek visual yang menyulitkan identifikasi cairan.
5. Karakteristik perangkat dan lingkungan acquisition dapat memengaruhi distribusi visual dataset.
6. Kemampuan generalisasi model terhadap data dari sumber, perangkat, atau lingkungan lain belum dapat diasumsikan tanpa pengujian lebih lanjut.

6.6 Recommendations

Pengguna dataset disarankan untuk menerapkan praktik evaluasi yang dapat mengurangi risiko data leakage dan overfitting.

Rekomendasi meliputi:

- melakukan pembagian data training, validation, dan testing secara tepat;

- memastikan tidak terdapat data yang sama atau sangat mirip pada subset yang berbeda;
- mempertahankan data original sebagai referensi;
- menggunakan beberapa metrik evaluasi, bukan hanya accuracy;
- melakukan error analysis terhadap hasil prediksi;
- menguji model pada kondisi visual yang berbeda dari data training;
- memeriksa apakah model memanfaatkan objek utama atau justru background, warna, maupun karakteristik acquisition sebagai shortcut feature.

Untuk dataset dengan jumlah sampel relatif kecil, interpretasi hasil evaluasi perlu dilakukan secara hati-hati karena perubahan beberapa sampel dapat memberikan pengaruh yang cukup besar terhadap metrik performa.

6.7 Dataset Versioning & Maintenance

Dataset dikelola menggunakan sistem versioning untuk menjaga keterlacakan setiap perubahan terhadap data, metadata, struktur dataset, dan dokumentasi.

Pemeliharaan dataset meliputi data review, data correction, data addition, quality control, dan pembaruan dokumentasi.

v0.x : Development / Draft

Digunakan selama tahap perencanaan, development, dan penyempurnaan Dataset Card sebelum dataset final dirilis.

Contoh:

- v0.1 : Initial Dataset Card draft
- v0.2 : Revisi acquisition protocol dan labeling criteria

v1.x : Initial Dataset Release

Digunakan setelah proses acquisition, labeling, dan quality control selesai.

Contoh:

- v1.0 : Initial dataset release
- v1.1 : Perbaikan label, metadata, atau penambahan data tanpa perubahan struktur utama.

v2.x : Major Revision

Digunakan apabila terdapat perubahan signifikan terhadap struktur dataset, skema metadata, atau ruang lingkup kelas.

Setiap perubahan versi harus disertai deskripsi perubahan dalam Version History.

6.8 Data Review & Correction

Dataset dapat ditinjau kembali apabila ditemukan masalah pada kualitas citra, label, metadata, duplikasi, atau distribusi data.

Data dapat memiliki status:

- accepted
- rejected
- needs_review

Apabila ditemukan kesalahan:

1. data diidentifikasi berdasarkan *image_id*;
2. citra dan metadata diperiksa kembali;
3. jenis kesalahan ditentukan;
4. koreksi dilakukan apabila diperlukan;
5. perubahan dicatat pada *version history*.

Data original hasil acquisition dipertahankan dan tidak ditimpa oleh hasil koreksi sehingga riwayat perubahan tetap dapat ditelusuri.

6.9 Data Addition

Data baru dapat ditambahkan apabila terdapat variasi yang belum cukup terwakili atau diperlukan untuk meningkatkan representasi dataset.

Data tambahan dapat berupa:

- jenis atau bentuk gelas baru;
- jenis cairan baru;
- tingkat pengisian tertentu;
- kondisi pencahayaan baru;
- sudut atau jarak kamera baru;
- background atau lingkungan baru.

Data tambahan harus mengikuti protokol acquisition dan labeling yang telah ditetapkan serta melalui quality control sebelum dimasukkan ke dataset final.

6.10 Dataset Responsibility & Contact

Dataset Curator

Dataset dikembangkan dan dikelola oleh pihak yang bertanggung jawab terhadap acquisition, labeling, quality control, metadata, serta dokumentasi dataset.

Dataset Curator: Adrian Bintang Saputera

Institution: Universitas Lambung Mangkurat

Course: Machine Learning 2

Dataset Card Author

Author: Adrian Bintang Saputera

Responsibility: Penyusunan dan pemeliharaan Dataset Card

Contact

Email: 2310817110006@mhs.ulm.ac.id

6.11 Version History

Version	Date	Status	Description
v0.1	08-09-2026	Draft	Penyusunan awal Dataset Card dan perencanaan dataset
v0.2		Draft	Revisi struktur, acquisition protocol, dan labeling criteria
v1.0		Planned/Initial Release	Dataset hasil acquisition, labeling, dan quality control


7. DATASET DOCUMENTATION

7.1 Dataset Folder Structure

Struktur folder digunakan untuk memisahkan data original, hasil preprocessing, hasil augmentation, metadata, dan dokumentasi.

Struktur:

```
empty-glass-vs-filled-glass/  
|  
|— raw/  
|   |— empty_glass/  
|   |— filled_glass/  
|  
|— processed/  
|  
|— augmented/  
|  
|— metadata/  
|   |— dataset_metadata.csv  
|  
|— documentation/  
|   |— dataset_card.md
```



7.2 Folder Contents


Folder raw/ berisi citra original hasil data acquisition. Folder processed/ digunakan untuk menyimpan hasil preprocessing, sedangkan augmented/ disediakan untuk hasil augmentation setelah tahap tersebut dilakukan dalam workflow penelitian.


Folder metadata/ berisi metadata tabular dataset, sedangkan folder documentation/ berisi dokumentasi dataset.

Contoh isi folder:

raw/

```
|— empty_glass/  
| |— IMG001.jpg  
| |— IMG002.jpg  
| |— ...  
|  
|— filled_glass/  
|— IMG036.jpg  
|— IMG037.jpg  
|— ...
```





7.3 Original Image Samples

Citra original merupakan hasil langsung dari proses data acquisition sebelum dilakukan preprocessing atau augmentation.

Contoh foto original:

Sample	Class
	Empty Glass



7.4 Annotated Image Samples

Proses anotasi dilakukan dengan memberikan label kelas pada setiap citra berdasarkan definisi Empty Glass atau Filled Glass.

Contoh anotasi dapat ditampilkan dengan menambahkan informasi label pada citra sebagai dokumentasi visual.

Contoh:




7.5 Preprocessing

Preprocessing dilakukan setelah proses acquisition, labeling, dan quality control. Tujuan preprocessing adalah menyeragamkan format dan ukuran citra agar dapat digunakan sebagai input model Deep Learning.

Data original pada folder raw/ tidak diubah secara langsung. Hasil preprocessing disimpan pada folder processed/.

Tahapan preprocessing



Resize

Citra akan diseragamkan ke ukuran 256×256 piksel agar memiliki dimensi input yang konsisten pada tahap pemodelan.

Format

Citra disimpan dalam format gambar yang umum digunakan, seperti .jpg atau .png, sesuai hasil acquisition.

Normalization

Normalisasi nilai piksel akan dilakukan sesuai dengan kebutuhan arsitektur model yang digunakan.

Augmentation

Augmentation tidak dilakukan pada tahap data acquisition. Augmentation hanya dilakukan setelah preprocessing apabila menjadi bagian dari workflow eksperimen model.

Dengan begitu urutannya jelas:

